

TUGAS BESAR BIG DATA GANJIL 2026



IMPLEMENTASI PIPELINE BIG DATA ETL DAN ELT SERTA DASHBOARD ANALITIK

Oleh :

Naufal Arya Putra Ultawijaya / 1103223204

Adhiaris Muhammad Azka / 1103220143

**PRODI S1 TEKNIK KOMPUTER
FAKULTAS TEKNIK ELEKTRO
UNIVERSITAS TELKOM
BANDUNG**

Abstrak

Penelitian ini menyajikan implementasi dua pendekatan pemrosesan data, yaitu Extract, Transform, Load (ETL) dan Extract, Load, Transform (ELT), terhadap dataset perjalanan ride-hailing di wilayah National Capital Region (NCR), India. Dataset yang digunakan terdiri atas dua sumber: data pemesanan perjalanan (`ncr_ride_bookings.csv`) sebanyak 150.000 catatan dengan 21 atribut, serta data cuaca (`weather_ncr_2024_full.json`) sebanyak 61.488 catatan per jam dari tujuh kota NCR sepanjang tahun 2024. Pipeline ETL menggunakan Python (pandas) untuk melakukan pembersihan dan transformasi data sebelum dimuat ke dalam basis data, sedangkan pipeline ELT memuat data mentah secara langsung ke PostgreSQL 18 sebagai data warehouse dan melakukan seluruh transformasi menggunakan SQL di dalam warehouse. Hasil dari kedua pipeline divisualisasikan melalui dashboard analitik menggunakan Tableau Desktop yang terhubung langsung ke data warehouse PostgreSQL.

Kata Kunci: ETL, ELT, Data Warehouse, PostgreSQL, Tableau, Ride-Hailing, NCR India

I. Pendahuluan

Perkembangan industri ride-hailing yang pesat menghasilkan volume data transaksi yang sangat besar. Data tersebut memiliki potensi analitik yang tinggi, namun memerlukan infrastruktur pemrosesan data yang andal dan efisien sebelum dapat dimanfaatkan untuk pengambilan keputusan bisnis. Dua pendekatan utama dalam pemrosesan data pada lingkungan data warehouse adalah ETL (Extract, Transform, Load) dan ELT (Extract, Load, Transform).

Pada pendekatan ETL, data diambil dari sumber, dibersihkan dan ditransformasikan terlebih dahulu sebelum dimuat ke dalam data warehouse. Sebaliknya, pada pendekatan ELT, data mentah dimuat langsung ke data warehouse dan seluruh proses transformasi dilakukan di dalam warehouse menggunakan kemampuan komputasi engine basis data. Laporan ini mendokumentasikan implementasi kedua pendekatan tersebut secara sistematis terhadap dataset perjalanan dan cuaca NCR India tahun 2024.

Tujuan penelitian ini adalah: (1) mengimplementasikan pipeline ETL menggunakan Python dan pandas; (2) mengimplementasikan pipeline ELT menggunakan PostgreSQL 18 sebagai data warehouse; (3) membangun dashboard analitik interaktif menggunakan Tableau Desktop; serta (4) membandingkan karakteristik dan hasil kedua pendekatan tersebut.

II. Dataset yang Digunakan

A. Dataset Pemesanan Perjalanan (`ncr_ride_bookings.csv`)

Dataset pertama merupakan data pemesanan ride-hailing di wilayah NCR India sepanjang tahun 2024. Dataset ini berformat CSV dan memuat informasi lengkap mengenai setiap transaksi pemesanan, mulai dari identitas pemesanan, status, hingga penilaian pengemudi dan pelanggan.

Tabel I. Karakteristik Dataset *ncr_ride_bookings.csv*

Atribut	Keterangan
Nama File	ncr_ride_bookings.csv
Format	Comma-Separated Values (CSV)
Jumlah Baris	150.000 catatan
Jumlah Kolom	21 atribut
Cakupan Waktu	Januari 2024 – Desember 2024
Wilayah	National Capital Region (NCR), India
Atribut Utama	Booking ID, Customer ID, Date, Time, Booking Status, Vehicle Type, Pickup/Drop Location, Booking Value, Ride Distance, Driver Ratings, Customer Rating, Payment Method

Kolom-kolom utama dalam dataset ini mencakup identitas pemesanan (Booking ID, Customer ID), informasi waktu dan lokasi (Date, Time, Pickup Location, Drop Location), jenis kendaraan (Vehicle Type), status pemesanan (Booking Status) dengan kategori: Completed, Cancelled by Driver, Cancelled by Customer, No Driver Found, dan Incomplete, serta informasi finansial dan penilaian (Booking Value, Ride Distance, Driver Ratings, Customer Rating, Payment Method).

B. Dataset Cuaca NCR (*weather_ncr_2024_full.json*)

Dataset kedua merupakan data cuaca per jam dari tujuh kota di wilayah NCR India sepanjang tahun 2024. Dataset ini berformat JSON dengan dua komponen utama, yaitu metadata dan data, yang masing-masing menyimpan informasi deskriptif dan rekaman cuaca per jam.

Tabel II. Karakteristik Dataset *weather_ncr_2024_full.json*

Atribut	Keterangan
Nama File	weather_ncr_2024_full.json
Format	JavaScript Object Notation (JSON)
Jumlah Record	61.488 catatan per jam
Jumlah Kolom	22 atribut
Cakupan Waktu	Januari 2024 – Desember 2024 (per jam)

Kota Tercakup	Delhi, Noida, Gurgaon, Faridabad, Ghaziabad, Meerut, dan satu kota tambahan NCR
Atribut Utama	date, hour, location, temperature_c, humidity_pct, rainfall_mm, windspeed_kmh, visibility_km, conditions, precip_type

Dataset cuaca mencatat kondisi atmosfer secara rinci setiap jam, mencakup suhu udara (temperature_c), kelembapan relatif (humidity_pct), curah hujan (rainfall_mm), kecepatan angin (windspeed_kmh), jarak pandang (visibility_km), serta deskripsi kondisi cuaca umum (conditions). Dataset ini digunakan untuk menganalisis korelasi antara kondisi cuaca dan pola pemesanan ride-hailing di wilayah NCR.

III. Pipeline ETL (Extract, Transform, Load)

A. Gambaran Umum ETL

Pendekatan ETL (Extract, Transform, Load) merupakan metode pemrosesan data di mana transformasi dan pembersihan data dilakukan sebelum data dimuat ke dalam sistem penyimpanan tujuan. Pada implementasi ini, proses transformasi dilakukan menggunakan Python dengan library pandas, sehingga data yang dimuat ke dalam PostgreSQL sudah dalam kondisi bersih dan siap dianalisis.

B. Tahap Extract

Pada tahap extract, kedua dataset dibaca dari file sumber menggunakan fungsi pandas. Data CSV dibaca menggunakan `pd.read_csv()` dan data JSON dibaca menggunakan `json.load()` yang kemudian dikonversi menjadi DataFrame.

```
import pandas as pd
import json

# Extract CSV
df_bookings = pd.read_csv('ncr_ride_bookings.csv')

# Extract JSON
with open('weather_ncr_2024_full.json', 'r') as f:
    raw_json = json.load(f)
df_weather = pd.DataFrame(raw_json['data'])
```

C. Tahap Transform

Seluruh proses pembersihan dan transformasi dilakukan menggunakan Python sebelum data dimuat ke dalam basis data. Transformasi mencakup:

- Pembersihan tipe data: konversi kolom Date ke tipe datetime, kolom numerik ke float
- Standarisasi teks: penghapusan spasi dan karakter kutip berlebih
- Penanganan nilai kosong: pengisian nilai default untuk kolom yang tidak terisi
- Pemetaan lokasi: pemetaan Pickup Location ke nama kota cuaca terdekat
- Penggabungan data: merge DataFrame booking dan cuaca berdasarkan tanggal, jam, dan kota
- Feature engineering: pembuatan kolom kategori suhu, kategori hujan, dan kategori jarak pandang

```
# Kategori Suhu
def get_temp_category(t):
    if t < 15: return 'Dingin (<15 derajat C)'
    elif t <= 30: return 'Sedang (15-30 derajat C)'
    else: return 'Panas (>30 derajat C)'
```

```

df_merged['Temperature Category'] =
df_merged['temperature_c'].apply(get_temp_category)

# Kategori Hujan
def get_rain_category(r):
    if r == 0: return 'Tidak Hujan'
    elif r <= 2.5: return 'Hujan Ringan'
    else: return 'Hujan Lebat'

df_merged['Rain Category'] = df_merged['rainfall_mm'].apply(get_rain_category)

```

D. Tahap Load

Setelah transformasi selesai, data yang sudah bersih disimpan ke dalam dua format: file CSV di folder `cleaned_data` sebagai data lake, dan tabel di PostgreSQL sebagai data warehouse menggunakan SQLAlchemy dan psycopg2.

```

from sqlalchemy import create_engine

engine = create_engine(
    'postgresql+psycopg2://postgres:password@localhost:5432/ncr_warehouse'
)

df_merged.to_sql(
    name='ride_bookings_weather_merged',
    con=engine,
    if_exists='replace',
    index=False
)

```

File output ETL yang dihasilkan meliputi: `ride_bookings_cleaned.csv` (data booking bersih), `weather_cleaned.csv` (data cuaca bersih), dan `ride_bookings_weather_merged.csv` (data gabungan yang telah ditransformasi).

IV. Pipeline ELT (Extract, Load, Transform)

A. Gambaran Umum ELT

Pendekatan ELT (Extract, Load, Transform) merupakan metode pemrosesan data modern di mana data mentah dimuat terlebih dahulu ke dalam data warehouse, kemudian seluruh transformasi dilakukan di dalam warehouse menggunakan SQL. Pendekatan ini memanfaatkan kemampuan komputasi engine PostgreSQL 18 sehingga tidak memerlukan transformasi di luar sistem warehouse.

B. Tahap Extract

Pada tahap extract, kedua dataset dibaca dalam kondisi mentah tanpa preprocessing menggunakan pandas. Seluruh kolom CSV dibaca sebagai tipe string untuk menjaga integritas data asli.

```
import pandas as pd
import json

# Extract CSV — semua kolom sebagai string (raw)
df_raw_bookings = pd.read_csv('ncr_ride_bookings.csv', dtype=str)

# Extract JSON
with open('weather_ncr_2024_full.json', 'r') as f:
    raw_json = json.load(f)
df_raw_weather = pd.DataFrame(raw_json['data'])

# Konversi kolom list ke string sebelum load
for col in df_raw_weather.columns:
    if df_raw_weather[col].dropna().apply(
        lambda x: isinstance(x, list)).any():
        df_raw_weather[col] = df_raw_weather[col].apply(
            lambda x: ', '.join(x) if isinstance(x, list) else x)
```

C. Tahap Load (Raw)

Data mentah dimuat langsung ke dalam tabel raw di PostgreSQL tanpa transformasi apapun. Tahap ini juga menyimpan metadata proses load, mencakup nama tabel, format sumber, jumlah baris, jumlah kolom, ukuran file, dan waktu load.

```
from sqlalchemy import create_engine

PG_CONN = 'postgresql://postgres:password@localhost:5432/ncr_warehouse'
engine = create_engine(PG_CONN)

# Load tabel raw
df_raw_bookings.to_sql('raw_ride_bookings', engine,
                        if_exists='replace', index=False)
df_raw_weather.to_sql('raw_weather', engine,
```

```

        if_exists='replace', index=False)

# Load metadata log
load_metadata.to_sql('metadata_load_log', engine,
        if_exists='replace', index=False)

```

D. Tahap Transform (SQL di dalam Warehouse)

Seluruh transformasi dilakukan menggunakan SQL di dalam PostgreSQL setelah data berada di warehouse. Proses transform mencakup empat tahapan berikut.

1. Data Cleaning (SQL)

Cleaning dilakukan menggunakan SQL CREATE TABLE AS SELECT dengan operasi CAST, TRIM, COALESCE, dan EXTRACT untuk menghasilkan tabel `clean_ride_bookings` dan `clean_weather`.

```

CREATE TABLE clean_ride_bookings AS
SELECT
    TRIM(REPLACE("Booking ID", "", ")) AS booking_id,
    CAST("Date" AS DATE) AS ride_date,
    EXTRACT(MONTH FROM CAST("Date" AS DATE))::INT AS month,
    EXTRACT(HOUR FROM CAST("Time" AS TIME))::INT AS hour,
    TRIM("Booking Status") AS booking_status,
    CAST(NULLIF(TRIM("Booking Value"), "") AS FLOAT) AS booking_value
FROM raw_ride_bookings
WHERE "Date" IS NOT NULL;

```

2. Penggabungan Tabel (SQL JOIN)

Penggabungan data booking dan cuaca dilakukan menggunakan LEFT JOIN di dalam warehouse berdasarkan tanggal, jam, dan kota pickup.

```

CREATE TABLE fact_ride_weather AS
WITH city_map AS (
    SELECT booking_id,
        CASE
            WHEN pickup_location ILIKE '%Noida%' THEN 'Noida'
            WHEN pickup_location ILIKE '%Gurgaon%' THEN 'Gurgaon'
            WHEN pickup_location ILIKE '%Faridabad%' THEN 'Faridabad'
            ELSE 'Delhi'
        END AS city
    FROM clean_ride_bookings
)
SELECT r.*, w.temperature_c, w.rainfall_mm, w.weather_condition
FROM clean_ride_bookings r
JOIN city_map cm USING (booking_id)
LEFT JOIN clean_weather w

```



```
ON r.ride_date = w.weather_date
AND r.hour = w.hour
AND cm.city = w.location;
```

3. Agregasi Metrik Analitik

Tiga tabel agregasi dibuat menggunakan SQL GROUP BY untuk menghasilkan metrik analitik bulanan, per tipe kendaraan, dan berdasarkan kondisi cuaca.

```
CREATE TABLE agg_monthly_bookings AS
SELECT
  month,
  COUNT(*) AS total_bookings,
  ROUND(SUM(booking_value)::NUMERIC, 2) AS total_revenue,
  ROUND(AVG(driver_rating)::NUMERIC, 3) AS avg_driver_rating,
  ROUND(100.0 * SUM(CASE WHEN booking_status='Completed'
    THEN 1 ELSE 0 END) / COUNT(*), 2) AS completion_rate_pct
FROM clean_ride_bookings
GROUP BY month ORDER BY month;
```

4. Feature Engineering (SQL Query)

Fitur-fitur baru dibuat menggunakan SQL CASE WHEN dan kalkulasi aritmetika di dalam warehouse, menghasilkan tabel feat_ride_enriched.

```
CREATE TABLE feat_ride_enriched AS
SELECT *,
  CASE
    WHEN hour BETWEEN 5 AND 9 THEN 'Morning Rush'
    WHEN hour BETWEEN 10 AND 16 THEN 'Midday'
    WHEN hour BETWEEN 17 AND 20 THEN 'Evening Rush'
    ELSE 'Night / Late Night'
  END AS time_segment,
  CASE WHEN ride_distance > 0
    THEN ROUND((booking_value/ride_distance)::NUMERIC, 2)
    ELSE NULL
  END AS revenue_per_km,
  CASE WHEN booking_value > 500 THEN 1 ELSE 0 END AS is_premium,
  CASE
    WHEN month IN (12,1,2) THEN 'Winter'
    WHEN month IN (3,4,5) THEN 'Summer'
    WHEN month IN (6,7,8,9) THEN 'Monsoon'
    ELSE 'Post-Monsoon'
  END AS season
FROM fact_ride_weather;
```

Tabel III. Ringkasan Tabel di Data Warehouse (ELT)

Fase	Nama Tabel	Baris	Kolom	Keterangan
RAW	raw ride bookings	150.000	21	Mentah
RAW	raw weather	61.488	22	Mentah
CLEAN	clean ride bookings	150.000	21	Bersih
CLEAN	clean weather	61.488	16	Bersih
FACT	fact ride weather	150.000	27	JOIN
AGG	agg_monthly_bookings	12	11	Agregat
AGG	agg_vehicle_performance	7	9	Agregat
AGG	agg_weather_impact	Variasi	8	Agregat
FEAT	feat Ride enriched	150.000	23	Fitur baru

V. Perbandingan ETL dan ELT

Kedua pendekatan memiliki karakteristik yang berbeda dalam hal lokasi transformasi, tools yang digunakan, dan struktur output yang dihasilkan. Tabel berikut merangkum perbandingan keduanya.

Tabel IV. Perbandingan Pipeline ETL dan ELT

Aspek	ETL	ELT
Urutan Proses	Extract → Transform → Load	Extract → Load → Transform
Lokasi Transform	Python (di luar warehouse)	SQL (di dalam warehouse)
Tools Transform	pandas, NumPy	PostgreSQL 18 SQL Engine
Data yang Dimuat	Data bersih (sudah ditransformasi)	Data mentah (raw)
Output Utama	CSV bersih + 1 tabel merged	9 tabel di warehouse
Jumlah Completed	93.000 booking	94.515 booking
Revenue Tertinggi	Maret: Rs 4.569.188	Maret: Rs 4.636.115
Dashboard	Tableau (dari tabel ETL)	Tableau (langsung ke PostgreSQL)

Perbedaan nilai pada kolom Completed dan Revenue antara ETL dan ELT disebabkan oleh perbedaan metode penanganan data saat transformasi. Pada ETL, beberapa baris mungkin terdrop selama proses cleaning berbasis Python sebelum dimuat. Pada ELT, data mentah dimuat secara utuh sehingga lebih sedikit data yang hilang dalam proses transformasi SQL.


VI. Dashboard Analitik Tableau

A. Konfigurasi Koneksi

Tableau Desktop terhubung langsung ke PostgreSQL 18 yang berjalan secara lokal pada laptop. Konfigurasi koneksi menggunakan parameter host localhost, port 5432, database ncr_warehouse, dengan autentikasi username dan password PostgreSQL. Koneksi langsung ini memenuhi persyaratan nomor satu kriteria dashboard, yaitu terhubung langsung dengan data warehouse.

B. Dashboard ETL

Dashboard ETL menampilkan analisis data yang bersumber dari tabel hasil pipeline ETL, yaitu tabel ride_bookings_weather_merged. Dashboard ini terdiri atas lima komponen visualisasi utama yang mencakup seluruh kriteria yang ditetapkan.




Gambar 1. Dashboard Analitik Tableau — Pipeline ETL

Komponen dashboard ETL meliputi: (1) Distribusi Status Booking berupa bar chart yang menampilkan jumlah booking per kategori status; (2) Kontribusi Pendapatan Berdasarkan Jenis Kendaraan berupa pie chart yang menunjukkan proporsi revenue per tipe kendaraan; (3) Tren Pendapatan Bulanan berupa line chart yang menyajikan tren nilai booking dari Januari hingga Desember 2024; (4) Top 10 Lokasi Pickup berupa horizontal bar chart yang menampilkan sepuluh lokasi penjemputan dengan jumlah booking tertinggi; serta (5) Pembatalan Booking Berdasarkan Kondisi Cuaca berupa stacked bar chart yang menganalisis korelasi antara kondisi cuaca dan pola pembatalan.

C. Dashboard ELT

Dashboard ELT menampilkan analisis data yang bersumber dari tabel-tabel hasil pipeline ELT di dalam PostgreSQL, khususnya tabel `feat_ride_enriched` dan tabel agregasi. Struktur visualisasi identik dengan dashboard ETL untuk memudahkan perbandingan hasil kedua pipeline.



Gambar 2. Dashboard Analitik Tableau — Pipeline ELT

Perbedaan nilai yang terlihat pada kedua dashboard merupakan konsekuensi langsung dari perbedaan metode transformasi. Dashboard ELT menampilkan nilai Completed sebesar 94.515 (berbanding 93.000 pada ETL) dan revenue bulan Maret sebesar Rs 4.636.115 (berbanding Rs 4.569.188 pada ETL). Hal ini mengkonfirmasi bahwa pipeline ELT mempertahankan lebih banyak data karena data mentah dimuat secara utuh sebelum ditransformasi.

D. Pemenuhan Kriteria Dashboard

Tabel V. Pemenuhan Kriteria Dashboard Analitik

No.	Kriteria	ETL	ELT
1	Terhubung langsung dengan data warehouse	Terpenuhi (PostgreSQL)	Terpenuhi (PostgreSQL)
2	Menampilkan Key Performance Indicators	Terpenuhi (count, revenue)	Terpenuhi (count, revenue)
3	Menyajikan analisis tren berbasis waktu	Terpenuhi (line chart bulanan)	Terpenuhi (line chart bulanan)

4	Menyajikan distribusi dan perbandingan data	Terpenuhi (pie, bar chart)	Terpenuhi (pie, bar chart)
5	Memiliki filter interaktif untuk eksplorasi data	Terpenuhi (filter per chart)	Terpenuhi (filter per chart)

VII. Kesimpulan

Laporan ini telah mendokumentasikan implementasi dua pipeline pemrosesan data, yaitu ETL dan ELT, terhadap dataset perjalanan ride-hailing NCR India (150.000 catatan) dan dataset cuaca NCR 2024 (61.488 catatan). Kedua pipeline berhasil diimplementasikan dengan hasil yang dapat divisualisasikan melalui dashboard analitik Tableau Desktop yang terhubung langsung ke data warehouse PostgreSQL 18.

Berdasarkan implementasi yang telah dilakukan, dapat disimpulkan bahwa: (1) Pipeline ETL berhasil membersihkan dan menggabungkan data menggunakan Python sebelum dimuat ke PostgreSQL, menghasilkan 93.000 booking completed dengan total revenue tertinggi pada bulan Maret sebesar Rs 4.569.188; (2) Pipeline ELT berhasil memuat data mentah ke PostgreSQL dan melakukan seluruh transformasi menggunakan SQL di dalam warehouse, menghasilkan 94.515 booking completed dengan total revenue tertinggi pada bulan Maret sebesar Rs 4.636.115; (3) Pendekatan ELT mempertahankan lebih banyak data karena tidak ada data yang terdrop selama proses loading; (4) Kedua dashboard Tableau berhasil memenuhi seluruh lima kriteria yang ditetapkan.

Kendaraan tipe Auto mendominasi pasar dengan kontribusi pendapatan sebesar 24,84% dari total revenue, diikuti oleh Go Mini (19,94%) dan Go Sedan (18%). Tren pendapatan bulanan menunjukkan puncak pada bulan Maret dan Oktober, serta lembah pada bulan Februari dan September. Kondisi cuaca berpengaruh pada pola pembatalan booking, dengan jumlah pembatalan tertinggi terjadi pada kondisi cuaca Partially Cloudy.

Referensi

- [1] W. H. Inmon, Building the Data Warehouse, 4th ed. Indianapolis, IN, USA: Wiley Publishing, 2005.
- [2] R. Kimball and M. Ross, The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling, 3rd ed. Indianapolis, IN, USA: Wiley, 2013.
- [3] PostgreSQL Global Development Group, "PostgreSQL 18 Documentation," 2024. [Online]. Available: <https://www.postgresql.org/docs/18/>
- [4] W. McKinney, Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [5] Tableau Software, "Tableau Desktop Documentation," 2024. [Online]. Available: <https://help.tableau.com/current/pro/desktop/en-us/>
- [6] A. Garg, "NCR Ride Booking Dataset 2024," Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/>